

Relatório Experimental: SARSA com Aproximação Linear no MountainCar-v0

Disciplina: Aprendizado por Reforço

Ambiente: Gymnasium MountainCar-v0

Algoritmo: SARSA com Aproximação Linear de Função via *Radial Basis Functions* (RBF)

1. Setup Experimental

O problema do *MountainCar-v0* consiste em controlar um carro subpotente em um vale unidimensional para alcançar o topo da montanha à direita ($x \geq 0.5$). O espaço de observação contínuo é bidimensional: posição $x \in [-1.2, 0.6]$ e velocidade $\dot{x} \in [-0.07, 0.07]$. As ações disponíveis são discretas: acelerar para a esquerda (0), não acelerar (1) e acelerar para a direita (2).

1.1 Modelo e Algoritmo

- **Aproximação Linear:** $Q(s, a) = \theta_a^\top \phi(s)$, onde $\theta_a \in \mathbb{R}^M$ são os pesos da ação a e $\phi(s) \in \mathbb{R}^M$ é o vetor de ativações RBF.
- **Extrator RBF:** Os estados contínuos são normalizados para o intervalo $[0, 1]^2$. São alocados $M = n_{\text{centers}}$ centros Gaussianos distribuídos em uma grade uniforme no espaço normalizado, com $\phi_i(s) = \exp\left(-\frac{\|s_{\text{norm}} - c_i\|^2}{2\sigma^2}\right)$, fixando-se $\sigma = 0.15$.
- **Regra de Atualização (SARSA):** $\theta_a \leftarrow \theta_a + \alpha[r + \gamma Q(s', a') - Q(s, a)]\phi(s)$, com fator de desconto $\gamma = 1.0$.
- **Política:** ϵ -gulosa com $\epsilon_{\text{inicial}} = 0.1$, decaimento multiplicativo de 0.995 por episódio e $\epsilon_{\text{mín}} = 0.01$.

1.2 Protocolo de Testes

Foi explorada uma grade completa de hiperparâmetros variando a taxa de aprendizado $\alpha \in \{0.005, 0.01, 0.02, 0.05, 0.1\}$ e o número de centros RBF $n_{\text{centers}} \in \{9, 16, 25, 36, 49\}$, totalizando 25 combinações. Cada configuração foi avaliada em **10 sementes aleatórias independentes** (seeds 42 a 51) ao longo de até 50.000 passos de ambiente. Registrou-se o número de passos necessários até que o agente atingisse **10 episódios de sucesso** (chegada ao objetivo antes do limite de 200 passos por episódio).

2. Resultados e Seleção das 5 Configurações

Para análise aprofundada, selecionou-se um conjunto ortogonal de 5 configurações que permite isolar simultaneamente os efeitos da resolução espacial e da taxa de aprendizado:

1. $\alpha = 0.10$, **49 centros:** Maior agressividade de aprendizado com alta capacidade representacional.
2. $\alpha = 0.05$, **49 centros:** Configuração de referência (*anchor*), com alta estabilidade e mínima variância.
3. $\alpha = 0.05$, **25 centros:** Resolução espacial intermediária com taxa de aprendizado ótima.
4. $\alpha = 0.01$, **49 centros:** Alta resolução espacial, porém com taxa de aprendizado conservadora.
5. $\alpha = 0.05$, **9 centros:** Resolução espacial grosseira (3×3), evidenciando o gargalo de capacidade.

Tabela 1: Estatísticas de Passos até 10 Sucessos (10 sementes por configuração)

Configuração	Taxa α	Centros RBF	Mediana	Média $\pm$ Desv. Padrão	Mínimo	Máximo	Taxa Sucesso
$\alpha = 0.10$ (49 centros)	0.10	49	3.230	3.404,8 $\pm$ 600,6	2.749	4.612	100%

Configuração	Taxa α	Centros RBF	Mediana	Média $\pm$ Desv. Padrão	Mínimo	Máximo	Taxa Sucesso
$\alpha = 0.05$ (49 centros)	0.05	49	4.530	4.489,2 $\pm$ 279,0	3.912	4.960	100%
$\alpha = 0.05$ (25 centros)	0.05	25	6.578	6.709,2 $\pm$ 413,4	6.214	7.670	100%
$\alpha = 0.01$ (49 centros)	0.01	49	11.752	11.846,2 $\pm$ 847,0	10.450	12.957	100%
$\alpha = 0.05$ (9 centros)	0.05	9	50.000	48.106,2 $\pm$ 3.484,6	38.542	50.000	40%

3. Visualização: Boxplot Comparativo




Figure 1: Boxplot comparativo dos passos até 10 sucessos para as 5 configurações seleccionadas.

4. Discussão e Interpretação Teórica

4.1 Efeito da Granularidade dos Centros RBF (Capacidade de Representação)

Comparando as configurações com $\alpha = 0.05$ fixo (49 centros, 25 centros e 9 centros): * **49 centros (7×7)**: Permite discretizar finamente o espaço de fase (posição $\times$ velocidade). O agente aprende a acumular energia cinética

embalando para trás e para frente rapidamente (mediana de 4.530 passos). * **25 centros** (5×5): Apresenta desempenho sólido (mediana de 6.578 passos, aumento de $\approx 45\%$ em relação a 49 centros), demonstrando boa capacidade com menor custo computacional. * **9 centros** (3×3): Provoca sobre-generalização extrema. A distância euclidiana entre centros adjacentes é de 0.5 no espaço normalizado, tornando impossível distinguir estados próximos com velocidades opostas. O agente sofre com interferência catastrófica na aproximação do valor Q , atingindo a meta em apenas 40% das sementes dentro dos 50.000 passos (mediana truncada em 50.000).

4.2 Efeito da Taxa de Aprendizado (α)

Fixando a malha em 49 centros e variando $\alpha \in \{0.01, 0.05, 0.10\}$: * $\alpha = 0.10$: Proporcionou a convergência mais rápida observada em toda a bateria experimental (mediana de apenas 3.230 passos). Devido à representação esparsa e local das bases RBF, taxas de aprendizado mais elevadas aceleram a propagação do sinal de recompensa negativa/positiva sem instabilizar a função de valor. * $\alpha = 0.05$: Apresentou a **menor dispersão** entre todas as configurações testadas ($\sigma = 279,0$ passos), indicando máxima robustez à semente inicial do ambiente. * $\alpha = 0.01$: Embora alcance 100% de taxa de sucesso, converge de forma significativamente mais lenta (mediana de 11.752 passos, $\approx 3,6\times$ mais demorado que $\alpha = 0.10$). As atualizações incrementais tornam a difusão do valor terminal muito gradual ao longo da trajetória de transições.

5. Conclusão

Os experimentos confirmam os princípios fundamentais descritos por Sutton & Barto (2018): 1. No MountainCar, uma representação contínua adequada do espaço de estados é pré-requisito indispensável para o sucesso do controle linear; representações de baixa dimensão ($n_{\text{centers}} \leq 9$) geram *underfitting* espacial crítico. 2. Com resolução suficiente ($n_{\text{centers}} \geq 25$), o SARSA com RBF demonstra alta robustez estocástica, e taxas de aprendizado moderadas a altas ($\alpha \in [0.05, 0.10]$) otimizam a velocidade de convergência sem incorrer em divergência numérica.